Compiladores (CC3001)
Aula 8: Âmbitos e Tabelas de Símbolos

Mário Florido

DCC/FCUP

2024

[dcc] FACULDADE DE CIÊNCIAS
UNIVERSIDADE DO PORTO

Esta aula

Análise semântica

Âmbitos

Tabelas de símbolos

Re-lembrar: fases dum compilador

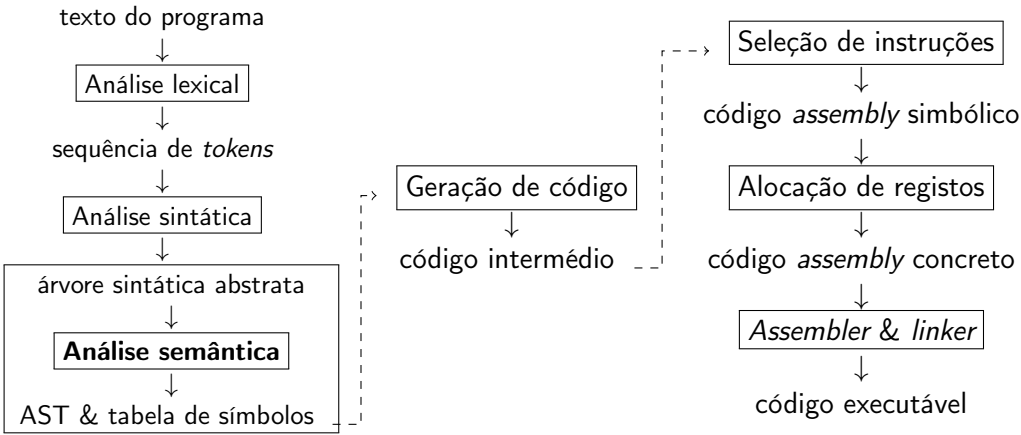

Todas as verificações de correção feitas pelo compilador que são dependentes de contexto.

Exemplos:

- garantir que as variáveis são declaradas antes do uso
- verificar que tipo declarado para cada variável é compatível com as operações efetuadas
- garantir que as funções são invocadas com o número e tipo correto de argumentos

- Em algumas linguagens e compiladores estas verificações eram feitas durante a análise sintática (e.g. primeiros compiladores de C)
- Em geral são dependentes de contexto, logo é melhor efetua-las como uma passagem separada sobre árvore sintática abstrata (AST)
- Frequentemente a análise semântica coleciona informação sobre identificadores (variáveis, funções, etc.) numa tabela de símbolos
- A tabela de símbolos será também usada para geração de código (e.g. para guardar informação sobre localização de cada variável)

Âmbitos

- Os identificadores numa linguagem de programação são nomes para diferentes entidades (variáveis, funções, tipos,...)
- Cada identificador é declarado uma vez e referido múltiplas vezes
- É comum que as declarações tenham âmbito limitado e que o identificador possa ser re-utilizado sem colisões
  - e.g. podemos declarar uma variável local a uma função com um mesmo nome que uma variável global

Exemplo

Identificar os âmbitos neste fragmento de C.

```
int i, j;           // global: i, j
int f(int size)     // global: f
{  char i, temp;    // função: size, i, temp
   ...              // re-declaração de i esconde a global
   { double j;      // bloco 1: j esconde a global
     ...
   }
   ...
   { char * j;     // bloco 2: j esconde a global
     ...
   }
}
```

Âmbito lexical

Âmbito lexical (também designado *âmbito estático*) cada uso de um identificador é sempre associado à declaração envolvente mais próxima na AST

- Esta é a forma usual de tratamento do âmbito de variáveis em todas as linguagens de programação genéricas (Pascal, C, C++, Java, Haskell, SML, etc.)
- Poucas linguagens usam outras regras para âmbitos (exemplo: primeiras versões de LISP e algumas linguagens de *scripting* usam *âmbito dinâmico*)

Âmbitos de funções

- Algumas linguagens permitem declarar funções em qualquer âmbito (inclusíve dentro de outras funções)
  - ALGOL 68 e familia: Pascal, Modula e Ada,...
  - todas as linguagens funcionais: Scheme, ML, Haskell,...
  - algumas linguagens de *scripting*: JavaScript, Ruby, Python,...
- Linguagens da família do C limitam a declaração das funções ao âmbito global (C) ou das classes (C++/Java)
  - em C *standard* não podemos declarar uma função *local* a uma outra função
  - mas o compilador GCC permite tais declarações (uma extensão)

Âmbitos de funções (cont.)


```
// Pascal
function E(x: real): real;
    function F(y: real): real;
    begin
        F := x + y
    end;
begin
    E := F(3) + F(4)
end;
```

```
-- Haskell
e :: Float -> Float
e x = f 3 + f 4
   where f y = x + y
```

```
// GNU C (não é standard)
float e(float x) {
  float f(float y) {
     return x + y;
  }
  return f(3) + f(4);
}
```

Âmbitos de funções (cont.)

Porquê declarar funções dentro de funções?

- esconder informação (funções auxiliares são locais)
- permite simplificar o controlo de fluxo
- nas linguagens funcionais: funções locais auxiliares são usadas em vez de ciclos

Âmbitos de funções (cont.)

Exemplo: testar primos (C vs. Haskell).

```c
int is_prime(int n) {
   int d = 2;
   if(n<=1)
       return FALSE;
   while(d*d <= n) {
     if (n%d == 0)
        return FALSE;
     d++;
   }
   return TRUE;
}
```

```haskell
isPrime :: Int -> Bool
isPrime n = n>1 && checkDivs 2
  where checkDivs d
          | n`mod`d==0 = False
          | d*d <= n   = checkDivs (d+1)
          | otherwise  = True
```

- Estruturas de dados que associam identificadores no código fonte a alguma informação; exemplos:
  - *valores* de variáveis (num interpretador);
  - *tipos* declarados para variáveis (num compilador);
  - tipo de *argumentos* e *resultado* (para funções)
  - *localização* em registos/memória (durante a geração de código)
- Num compilador a tabela de símbolos é construida na análise semântica e usada durante a geração de código

- É comum as linguagens dividirem identificadores em espaços de nomes separados
  - e.g. em Haskell podemos usar o mesmo nome para um *tipo* e um *construtor*

```
data Expr = Int Int | Add Expr Expr
```

  - sistemas de módulos ou *packages* também definem espaços de nomes separados
- Podemos usar tabelas de símbolos separadas para diferentes espaços
- Alternativa: usar uma tabela única e distinguir os nomes por prefixos

```
Prelude.lookup    -- no prelúdio
Data.Map.lookup   -- no módulo Data.Map
```

Operações sobre a tabela de símbolos

Operações fundamentais:

inicializar uma *tabela vazia*;

inserir dado o *identificador* e *informação* inserir uma nova entrada numa tabela; (se o identificador já ocorre, a informação deve alterada)

procurar dado o *identificador* devolve a *informação* associada (caso exista) ou um sinal de falha (i.e. uma excepção ou um resultado opcional)

Suportadas em vários tipos para *dicionários*. Exemplos:

- `Map` em Java
- `Data.Map` em Haskell
- `dict` em Python
- `std::map` em C++

Operações sobre a tabela de símbolos (cont.)

Necessitamos de duas operações extra para âmbitos:

abrir iniciar num novo âmbito (i.e. à entrada de um bloco ou função)

fechar terminar o âmbito atual *repondo todas as associações como estavam antes da abertura do âmbito*

Nota: não é suficiente apagar entradas ao fechar o âmbito (é necessário repor as associações anteriores).

- Podemos implementar usando diferentes estruturas concretas: listas ligadas, árvores de pesquisa, tabelas de partição (*hash tables*)
- Podemos usar estruturas persistentes ou efémeras:

  persistentes as operações preservam a versão anterior da estrutura

  efémeras as operações destroem a versão anterior da estrutura
- Estruturas dados em linguagens funcionais são normalmente persistentes enquanto em linguagens imperativas são normalmente efémeras

Estrutura efémera (C, Java, etc.)

```
xs = new List(0,1,2);
ys = new List(3,4,5);
xs.append(ys);
```

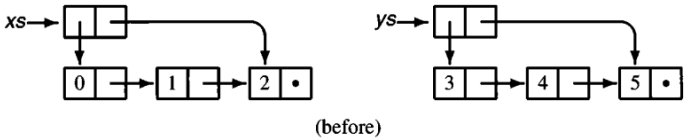

(before)

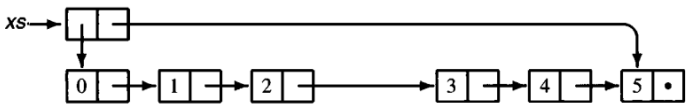

(after)

Estrutura persistente (Haskell, SML, etc.)

```
xs = [0,1,2]
ys = [3,4,5]
zs = xs ++ ys
```

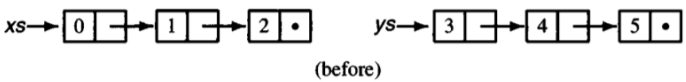

(before)

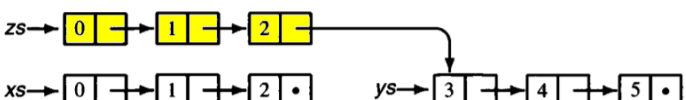

(after)

Outro exemplo: conjuntos implementados como *árvores binárias de pesquisa*.

```
xs = Set.fromList ["a","b","c","d","f","g"]
ys = Set.insert "e" xs
```

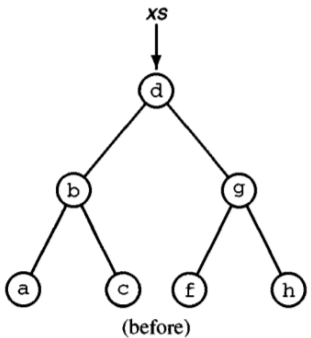

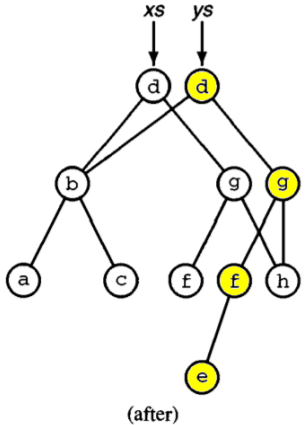

- Se a tabela for persistente: a implementação de âmbitos é trivial
  1. guardar uma referência para a tabela ao abrir o âmbito;
  2. restaurar a tabela ao sair do âmbito.[1]
- Se a tabela for efémera: necessitamos de tabalho extra
  (e.g. guardar valores anteriores das chaves inseridas e defazer as alterações)

[1] Espaço em memória não utilizado será libertado pelo recoletor de lixo.

Uma lista de pares *(identificador,info)*:

inicializar a lista vazia `[]`;

inserir acrescentar *(ident,info)* ao início da lista;

procurar do ínicio para o final da lista (i.e. `lookup` do prelúdio de Haskell);

abrir âmbito lembrar a tabela atual;

fechar âmbito voltar à tabela guardada.

Exemplo: tabela para tipos

```
int i, j;
int f(int size)
{  char i, temp;
   ...
   { double j;
     ...
```

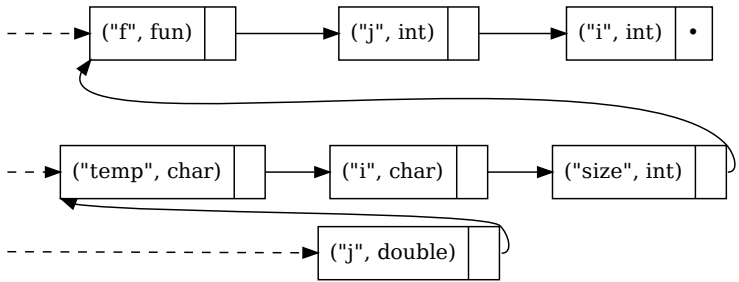

Opera de forma similar às listas funcionais.

inicializar	uma pilha vazia;
inserir	empilhar *(name,info)*
procurar	do topo para pilha para o início;
abrir âmbito	guardar o atual topo da pilha;
fechar âmbito	repor o topo da pilha guardado.

```
int i, j;
int f(int size)
{  char i, temp;
   ...
   { double j;
     ...
```

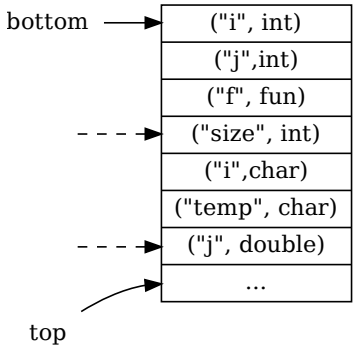

- Tabelas implementadas como listas ou pilhas usam pesquisa sequêncial: $O(n)$ para uma tabela com n entradas
- Não é muito importante num protótipo ou compilador experimental...
- Mas num compilador real, n pode ser bastante grande (número de identificadores do programa e bibliotecas)
- Alternativas mais eficientes: árvores de pesquisa binária ou tabelas de partição

- Baseadas numa ordem total sobre as chaves (>, <, ==)
- Árvores auto-equilibradas (AVL, Red-Black) garantem pesquisa e inserção em $O(\log n)$ comparações no pior caso
- Implementações funcionais são usualmente persistentes:
  - e.g. `Data.Map` em Haskell
  - OK para tabelas de símbolos (mas as *tabelas de partição* são uma melhor opção)
- Implementações imperativas são usualmente efémeras:
  - e.g. `java.util.TreeMap` em Java
  - não são a boa opção para tabelas de símbolos (por causa da dificuldade de tratamento de âmbitos)

- Ao pesquisar numa árvore binária necessitamos de comparar chaves
- Contudo: a comparação de cadeias não é $O(1)$ (necessita de percorrer as sequências dos carateres)
- Alternativa: pesquisa sem comparações usando uma tabela de partição (*hash tables*)
- Vamos ver uma implementação imperativa simples apropriada para tabelas de símbolos

- Um *array* $b[0], \ldots, b[N-1]$ de listas ligadas (*buckets*)
- Uma função h de *hash* que converte uma chave (identificador) num *inteiro* no intervalo 0 a $N-1$ (correspondente a um dos *buckets*)
- Pesquisamos uma chave k no *bucket* $b[h(k)]$
- Quando duas chaves diferentes têm o mesmo *hash*: resolver a colisão usando a lista ligada
- Escolher o número n de *buckets* e a função h tal que:
  1. a função seja rápida de calcular
  2. distribua as chaves pelos *buckets* de forma o mais uniforme possível
- Se a função de *hash* e número de *buckets* forem bem escolhidos as colisões são raras e a pesquisa é eficiente (na prática: tempo constante)

Exemplo:

- Uma tabela de partição com $N = 5$ (número de *buckets*) e 3 entradas (`i`,`j`,`f`)
- Supondo que $h(\texttt{i}) = 0$, $h(\texttt{j}) = 1$ e $h(\texttt{f}) = 4$
- Não há colisões: cada *bucket* têm uma só entrada

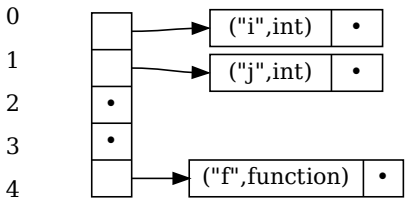

(Nota: na prática N será muito maior — na ordem das centenas ou milhares.)

- Inserimos novas entradas para `i`, `size` e `temp`
- Temos colisões na chave repetida (`i`) e (supondo) também numa diferente: $h(\texttt{size}) = h(\texttt{j}) = 1$
- Resolvemos as colisões colocando as novas entradas à cabeça:

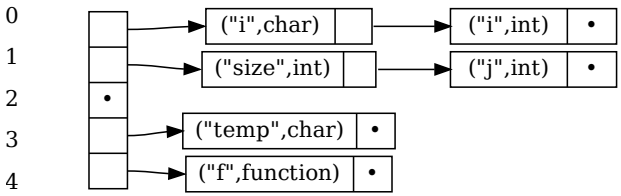

- Pesquisamos sempre do início para o fim de cada lista
- No final de um âmbito removemos todas as entradas introduzidas

Como escolher uma função de *hash* para identificadores?

$$x = x_0 x_1 \ldots x_{k-1}$$

(k é o comprimento da cadeia e x_i são os códigos dos carateres).

- Muitas heurísticas diferentes dependendo de *trade-offs* (velocidade / colisões)
- Solução simples: somar os códigos multiplicados por potências de α

$$h(x) = (x_0 \alpha^{k-1} + x_1 \alpha^{k-2} + \cdots + x_{k-1} \alpha^0) \bmod N$$

  Escolhendo α potência de 2: podemos implementar as multiplicações como *shifts*
- Numa implementação real: deve usar implementações de algoritmos mais robustos...

Exemplo de implementação em C ($\alpha = 2^4 = 16$).

```
#define N ...

unsigned hash(char *ptr) {
   unsigned h = 0;
   while(*ptr) {
       h = (h<<4) + (unsigned)(*ptr++);
  }
  return (h % N);
}
```

Tabelas de partição funcionais

- Existem implementações funcionais de tabelas de partição
- Em vez de *arrays* imperativos usam árvores *n*-árias (*hashed array mapped tries*)
- Em Haskell: `Data.HashMap` na biblioteca `unordered-containers`
- É uma estrutura persistente (tal como `Data.Map`)
  (facilita o tratamento de âmbitos)
- A função de *hash* é dada por uma instância da classe *Hashable*
  (não necessita de implementar)

Sugestões para o trabalho

- A eficiência não é crítica!
- Preferir uma solução simples que obviamente não tem erros a uma complicada em que os erros não são óbvios
- Implementar a tabela como um módulo com *interface* bem definida:
  - mais simples para garantir a correção das operações
  - pode mudar a implementação mais tarde (se tiver tempo)
- Em linguagem C: implemente usando uma pilha
- Em Haskell: implemente com `Data.Map` ou `Data.HashMap` (são igualmente simples)