

Compiladores (CC3001)

Aula 10: Geração de código intermédio

Mário Florido

DCC/FCUP

2024



FACULDADE DE CIÊNCIAS
UNIVERSIDADE DO PORTO

Códigos intermédios

Código de três endereços

Tradução para código intermédio

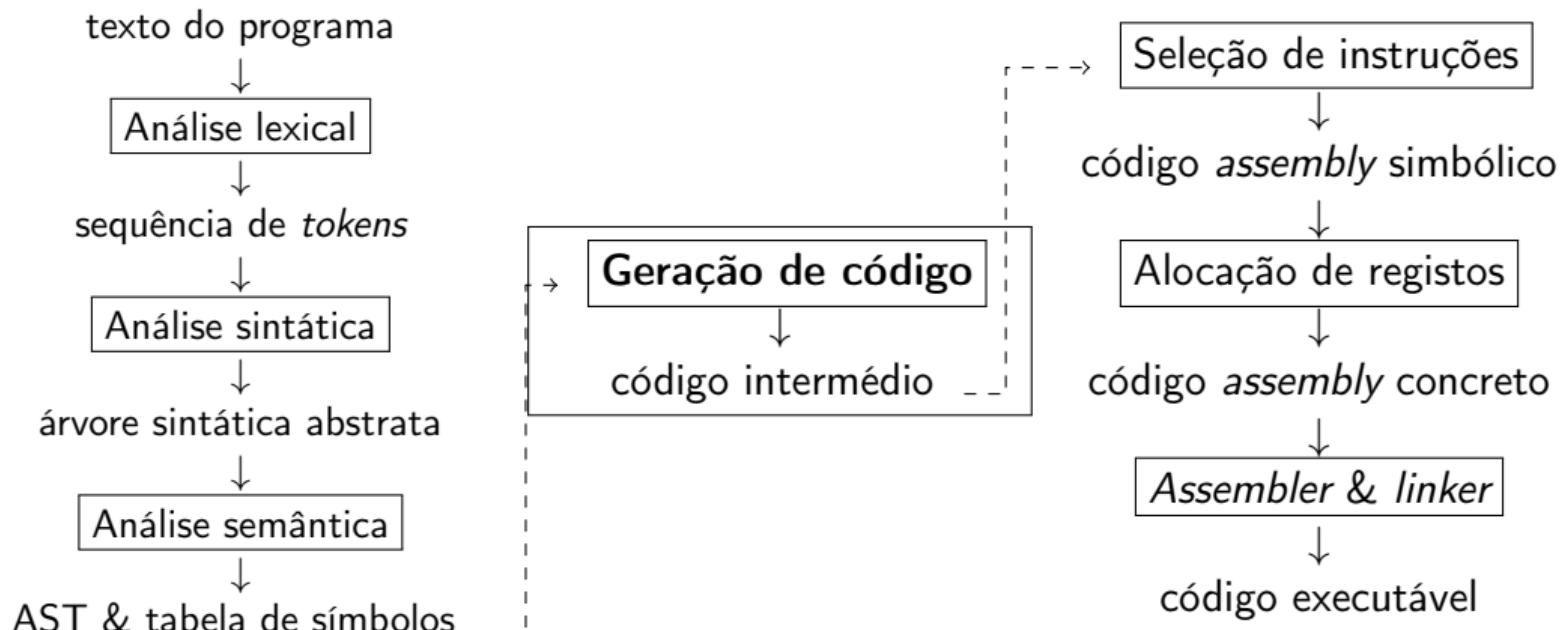
Expressões

Comandos

Definição e chamada de funções

Operadores lógicos

Arrays



- ▶ Linguagens usadas nas fases intermédias da compilação
- ▶ Compromisso entre a linguagem-fonte e o código-máquina real
- ▶ Objetivo: **facilitar a compilação**
- ▶ Diferentes opções:
 - mais alto-nível facilita a **tradução a partir da linguagem-fonte** (mas dificulta a geração de código máquina)
 - mais baixo-nível facilita a **geração de código-máquina** (mas dificulta tradução da linguagem-fonte)
- ▶ Também podem ser usados para implementar **interpretadores**

- ▶ As linguagens de alto-nível são mais distintas entre si do que as linguagens de máquina
- ▶ A linguagem fonte frequente determina o código intermédio, e.g.:
 - ▶ *Java Virtual Machine* (JVM) para compilar Java
 - ▶ *Low Level Virtual Machine* (LLVM) para compilar C/C++
- ▶ Mas também é possível re-utilizar o código intermédio:
 - ▶ Scala e Clojure compilam para a JVM
 - ▶ Rust, Swift e Julia compilam para LLVM
- ▶ Alguns compiladores usam mais do que um código intermédio (e.g. o GHC usa 3 linguagens intermédias na compilação de Haskell)

Vamos estudar um **código intermédio de três endereços**:

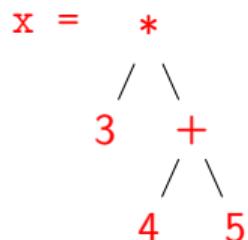
- ▶ Número arbitrário de registos temporários
- ▶ Operações com 2 ou 3 operandos
- ▶ Sem instruções de processadores específicos
- ▶ Adequado para implementar uma linguagem imperativa simples (e.g. C ou Pascal)

Queremos gerar código para a atribuição

$$x = 3 * (4 + 5)$$

Podemos decompor em atribuições mais simples usando **variáveis temporárias**:

```
t1 = 3
t2 = 4
t3 = 5
t4 = t2+t3
t5 = t1*t4
x = t5
```



- ▶ Cada variável corresponde a um **nó da expressão**
- ▶ Cada operação tem (no máximo) três variáveis (“endereços”)
- ▶ Podemos gerar as atribuições com uma **tradução dirigida pela sintaxe**

Instr → **temp** := *Atom*

| **temp** := **temp** **binop** *Atom*
| **LABEL** **label**
| **JUMP** **label**
| **COND** **temp** **relop** *Atom* **label** **label**

Atom → **temp** | **num**

- ▶ identificadores (**temp**), atribuições e constantes (**num**)
- ▶ operações binárias **binop**: +, *, etc.
- ▶ comparações **relop**: <, >, ==, etc.
- ▶ etiquetas, saltos incondicionais e condicionais

```
while (b != 0) {  
    r = a%b;  
    a = b;  
    b = r;  
}
```

```
LABEL loop  
COND b != 0 next end  
LABEL next  
r := a % b  
a := b  
b := r  
JUMP loop  
LABEL end
```

- ▶ Sem declarações de variáveis ou funções (apenas o corpo)
- ▶ LABEL define uma etiqueta para um ponto no programa
- ▶ Apenas duas formas de controlo de fluxo:
 - JUMP *label* salto incondicional para *label*
 - COND *cond* *label_t* *label_f* testa uma condição e salta para *label_t* ou *label_f*¹
- ▶ As condições têm ser comparações simples

$$cond \rightarrow id \text{ relop } id \mid id \text{ relop } const$$

¹No livro: IF...THEN...ELSE

- ▶ Variáveis, expressões aritméticas e comparações
- ▶ Atribuições, *if/else*, ciclos *while*
- ▶ A tradução para código intermédio será **dirigida pela sintaxe**
 - ▶ uma função recursiva por cada categoria sintática (expressões, comandos, etc.)
 - ▶ passamos argumentos extra dependendo do contexto
 - ▶ o resultado é uma **lista de instruções**
 - ▶ na exposição usamos a sintaxe concreta; na implementação usamos a AST

$$Exp \rightarrow \text{num} \mid \text{id} \mid Exp \text{ binop } Exp$$

- ▶ Uma **tabela de símbolos** para associar identificadores do programa com temporários do código intermédio
- ▶ Para gerar nomes temporários usamos *pseudo-funções*

$$\textit{newTemp} : () \rightarrow Temp$$
$$\textit{newLabel} : () \rightarrow Label$$

- ▶ Não são funções puras: devem retornar uma **variáveis ou etiquetas distintas** de cada vez que são chamadas
- ▶ A função de tradução

$$\textit{transExpr} : (Exp, Table, Temp) \rightarrow [Instr]$$

recebe também o **destino** onde colocar o resultado (*atributo herdado*)

<i>transExpr (expr, table, dest) = case expr of</i>	
num	<i>return [dest := num]</i>
id	<i>temp = lookup(id, table)</i> <i>return [dest := temp]</i>
e₁ binop e₂	<i>t₁ = newTemp()</i> <i>t₂ = newTemp()</i> <i>code₁ = transExpr(e₁, table, t₁)</i> <i>code₂ = transExpr(e₂, table, t₂)</i> <i>return code₁ ++ code₂ ++ [dest := t₁ binop t₂]</i>

Assumindo a tabela $[x \mapsto t_1, y \mapsto t_2]$ traduzir a expressão

$x + (3*y)$

colocando o resultado em t_0 .

```
t3 := t1  
t5 := 3  
t6 := t2  
t4 := t5 * t6  
t0 := t3 + t4
```

$$\overbrace{t_3}^x + \underbrace{\overbrace{3}^{t_5} * \overbrace{t_6}^y}_{t_4} \overbrace{\quad}^{t_0}$$

(Usamos temporários t_3, t_4, \dots)

- ▶ Atribuições
- ▶ Condicionais (com e sem *else*)
- ▶ Ciclos *while*
- ▶ Comparações entre expressões
- ▶ Blocos

$$\begin{aligned} Stm \rightarrow & \mathbf{id} = Exp; \\ | & \mathbf{if}(Cond) \; Stm \\ | & \mathbf{if}(Cond) \; Stm \; \mathbf{else} \; Stm \\ | & \mathbf{while}(Cond) \; Stm \\ | & \{ \; StmList \; \} \end{aligned}$$
$$Cond \rightarrow Exp \; relop \; Exp$$
$$StmList \rightarrow Stm \; StmList \; | \; \epsilon$$

Função de tradução:

$$transStm : (Stm, Table) \rightarrow [Instr]$$

- ▶ A definição de *transStm* é dirigida pela sintaxe
- ▶ Casos mais simples: atribuições e blocos

transStm (stm, table) = case stm of

id = *expr*;

dest = *lookup(id, table)*

return *transExpr(expr, table, dest)*

{ *stm₁* ... *stm_n* }

code₁ = *transStm(stm₁, table)*

:

code_n = *transStm(stm_n, table)*

return *code₁* ++ ··· ++ *code_n*

- ▶ Uma função auxiliar para compilar condições
- ▶ Argumentos extra: etiquetas $label_t$ e $label_f$ para onde saltar caso *true/false* (*atributos herdados*)
- ▶ Vai ser usada na tradução de *if/else* e *while*

$transCond : (Cond, Table, Label, Label) \rightarrow [Instr]$
 $transCond (cond, tabl, label_t, label_f) = \text{case } cond \text{ of}$

$expr_1 \text{ relop } expr_2 \quad t_1 = newTemp()$
 $\qquad\qquad\qquad t_2 = newTemp()$
 $\qquad\qquad\qquad code_1 = transExpr(expr_1, tabl, t_1)$
 $\qquad\qquad\qquad code_2 = transExpr(expr_2, tabl, t_2)$
 $\qquad\qquad\qquad \text{return } code_1 ++ code_2 ++ [\text{COND } t_1 \text{ relop } t_2 \text{ } label_t \text{ } label_f]$

```
transStm (stm, table) = case stm of
  if(cond) stm1    label1 = newLabel()
               label2 = newLabel()
               code1 = transCond(cond, label1, label2, table)
               code2 = transStm(stm1, table)
               return code1 ++[LABEL label1] ++code2 ++[LABEL label2]
```

transStm (stm, tabl) = case stm of

if(Cond) stm₁ *label₁ = newLabel()*
else stm₂ *label₂ = newLabel()*
 label₃ = newLabel()
 code₁ = transCond(cond, label₁, label₂, table)
 code₂ = transStm(stm₁, table)
 code₃ = transStm(stm₂, table)
 return code₁ ++ [LABEL label₁] ++ code₂ ++ [JUMP label₃]
 ++ [LABEL label₂] ++ code₃ ++ [LABEL label₃]

Assumindo a tabela $[x \mapsto t_0, y \mapsto t_1, z \mapsto t_2]$ vamos traduzir o comando seguinte.

```
if (x < y)          t3 := t0
    z = y;           t4 := t1
else                  COND t3 < t4 label1 label2
    z = x;           LABEL label1
                      t2 := t1
                      JUMP label3
                      LABEL label2
                      t2 := t0
                      LABEL label3
```


Assumindo a tabela $[n \mapsto t_0, r \mapsto t_1]$
vamos traduzir os comandos seguintes.

```
{  
    n = 5;  
    r = 1;  
    while (n>0) {  
        r = r*n;  
        n = n-1;  
    }  
}
```

```
t2 := 5  
t0 := t2  
t3 := 1  
t1 := t3  
LABEL label1  
t4 := t0  
t5 := 0  
COND t4 > t5 label2 label3  
LABEL label2  
t6 := t1  
t7 := t0  
t1 := t6 * t7  
t8 := t0  
t9 := 1  
t0 := t8 - t9  
JUMP label1  
LABEL label3
```

- ▶ Vamos acrescentar a definição e chamada de funções como ao código intermédio
- ▶ Restrição: no código intermédio os argumentos de funções devem ser **temporários**
 - ▶ expressões complexas têm de ser calculadas e colocadas em temporários antes da chamada da função
- ▶ A implementação de passagem de parâmetros usando registo e/ou pilha fica para a tradução para código *assembly*
- ▶ Simplificação: um único tipo **int**

Linguagem fonte
$$\text{Function} \rightarrow \text{int id}(\text{Decls}) \{ \text{Decls}; \text{Stms} \}$$
$$\text{Decls} \rightarrow \text{int id}, \dots, \text{id}$$
$$\text{Stm} \rightarrow \dots$$
$$| \quad \text{return } \text{Exp};$$
$$\text{Exp} \rightarrow \dots$$
$$| \quad \text{id}(\text{Exp}, \dots, \text{Exp})$$
Código intermédio
$$\text{Function} \rightarrow \text{id}(\text{TempList}) [\text{InstrList}]$$
$$\text{TempList} \rightarrow \text{temp}, \dots, \text{temp}$$
$$\text{InstrList} \rightarrow \text{Instr}; \dots; \text{Instr}$$
$$\text{Instr} \rightarrow \dots$$
$$| \quad \text{temp} := \text{CALL id}(\text{TempList})$$
$$| \quad \text{RETURN temp}$$

```
int max(int x, int y)
{
    if (x<y) return y;
    else return x;
}
```

```
max(t0,t1) [
    COND t0 < t1 ltrue lfalse
    LABEL ltrue
    RETURN t1
    LABEL lfalse
    RETURN t0
]
```

```
int max3(int x, int y, int z)          max(t0,t1,t2) [  
{                                         t3 := t0  
    int m;                           COND t3 < t1 L1 L2  
    m = x;                           LABEL L1  
    if (m < y) m = y;                t3 := t1  
    if (m < z) m = z;                LABEL L2  
    return m;                         COND t3 < t2 L3 L4  
}                                         LABEL L3  
                                         t3 := t2  
                                         LABEL L4  
                                         RETURN t3  
                                         ]
```

```
int max3(int x, int y, int z)
{
    return max(x,max(y,z));
}
```

```
max3(t0, t1, t2) [
    t3 := CALL max(t1, t2)
    t4 := CALL max(t0, t3)
    RETURN t4
]
```

- ▶ Na tradução da chamada $f(e_1, \dots, e_n)$ necessitamos de traduzir cada um dos argumentos
- ▶ Usamos uma função auxiliar *transArgs* que retorna também a lista de temporários
- ▶ Na tradução de **return** e usamos *transExpr* para gerar código para a expressão

$$\begin{array}{ll} \text{transExpr } (\textit{exp}, \textit{table}, \textit{dest}) & = \text{case } \textit{exp} \text{ of} \\ \text{id}(\textit{exprs}) & \quad (\textit{code}, \textit{temps}) = \text{transArgs}(\textit{exprs}, \textit{table}) \\ & \quad \text{return } \textit{code} ++ [\textit{dest} := \text{CALL id}(\textit{temps})] \end{array}$$

$$\begin{array}{ll} \text{transArgs } (\textit{exprs}, \textit{table}) & = \text{case } \textit{exprs} \text{ of} \\ \textit{e}_1, \dots, \textit{e}_n & \quad t_1 = \text{newTemp}() \\ & \quad \vdots \\ & \quad t_n = \text{newTemp}() \\ & \quad \textit{code}_1 = \text{transExpr}(\textit{e}_1, \textit{table}, t_1) \\ & \quad \vdots \\ & \quad \textit{code}_n = \text{transExpr}(\textit{e}_n, \textit{table}, t_n) \\ & \quad \text{return } (\textit{code}_1 ++ \dots ++ \textit{code}_n, [t_1, \dots, t_n]) \end{array}$$

- ▶ Traduzimos cada definição de função separadamente
- ▶ Os temporários são locais a cada função
- ▶ Os primeiros temporários t_0 , t_1 , etc. são usados para os argumentos da funções
- ▶ Os restantes são usados para as variáveis locais e valores intermédios
- ▶ Construimos a tabela de símbolos e aplicamos a tradução de comandos

- ▶ Vamos extender condições com **operadores lógicos**: conjunção (`&&`), disjunção (`||`) e negação (`!`)
- ▶ A maioria das linguagens de programação implementa conjunção e disjunção usando *short-circuit evaluation*:
 - ▶ não avaliar o segundo argumento se o primeiro determinar o resultado
- ▶ Permite simplificar o controlo de fluxo, e.g.

```
if (k!=0 && n%k==0) { ... }
```

é equivalente a

```
if (k!=0) { if (n%k==0) { ... } }
```

- ▶ Vamos também permitir usar de **condições como expressões** e vice-versa, e.g.

```
c = a==0 || b==0;  
if(c) { ... }
```

$Exp \rightarrow \text{num}$

- | **id**
- | $Exp \text{ binop } Exp$
- | $\text{id}(Exps)$
- | **true**
- | **false**
- | $Cond$

 $Cond \rightarrow Exp \text{ relop } Exp$

- | $!Cond$
- | $Cond \And Cond$
- | $Cond \Or Cond$
- | **true**
- | **false**
- | Exp

- ▶ Representamos valores lógicos pelos inteiros 0 e 1
- ▶ Traduzimos true e false por uma atribuição direta
- ▶ Outros casos: usamos a tradução de condições para atribuir o resultado correto

transExpr (exp, table, dest) = case expr of

:

true *return [dest := 1]*

false *return [dest := 0]*

cond *label₁ = newLabel()*

label₂ = newLabel()

label₃ = newLabel()

code₁ = transCond(cond, table, label₁, label₂)

*return code₁ ++[LABEL label₁, dest := 1, JUMP label₃]
 ++ [LABEL label₂, dest := 0, LABEL label₃]*

Recordar: a função de tradução

$$\text{transCond} (\text{cond}, \text{table}, \text{label}_t, \text{label}_f)$$

gera código que salta para label_t e label_f conforme a condição é verdadeira ou falsa.

Vamos ver como extender para os operadores lógicos.

transCond (cond, table, label_t, label_f) = case cond of

e₁ relop e₂

:

(como anteriormente)

true

return [JUMP label_t]

false

return [JUMP label_f]

!cond₁

transCond(cond₁, table, label_f, label_t)

- ▶ Constantes true e false traduzem-se em saltos incondicionais
- ▶ A tradução da negação de uma condição apenas troca as etiquetas

$$\text{transCond}(\text{cond}, \text{table}, \textcolor{blue}{label}_t, \textcolor{red}{label}_f) = \text{case cond of}$$

$$\text{cond}_1 \&\& \text{cond}_2 \quad \text{label}_2 = \text{newLabel}()$$
$$\quad \quad \quad \text{code}_1 = \text{transCond}(\text{cond}_1, \text{table}, \text{label}_2, \textcolor{red}{label}_f)$$
$$\quad \quad \quad \text{code}_2 = \text{transCond}(\text{cond}_2, \text{table}, \textcolor{blue}{label}_t, \textcolor{red}{label}_f)$$
$$\quad \quad \quad \text{return code}_1 \text{ ++ [LABEL } \text{label}_2 \text{]} \text{ ++ code}_2$$

$$\text{cond}_1 \mid\mid \text{cond}_2 \quad \text{label}_2 = \text{newLabel}()$$
$$\quad \quad \quad \text{code}_1 = \text{transCond}(\text{cond}_1, \text{table}, \textcolor{blue}{label}_t, \text{label}_2)$$
$$\quad \quad \quad \text{code}_2 = \text{transCond}(\text{cond}_2, \text{table}, \textcolor{blue}{label}_t, \textcolor{red}{label}_f)$$
$$\quad \quad \quad \text{return code}_1 \text{ ++ [LABEL } \text{label}_2 \text{]} \text{ ++ code}_2$$

A tradução de conjunções e disjunções introduz uma etiqueta temporária para avaliar as condições em sequência

$$\begin{array}{ll} transCond(cond, table, \textcolor{blue}{label}_t, \textcolor{red}{label}_f) & = \text{case } cond \text{ of} \\ \exp & t = newTemp() \\ & code_1 = transExpr(exp, table, t) \\ & \text{return } code_1 ++ [\text{COND } t != 0 \text{ } \textcolor{blue}{label}_t \text{ } \textcolor{red}{label}_f] \end{array}$$

Outros casos: traduzimos uma expressão e comparamos o resultado com zero

Supondo $[a \mapsto t_0, b \mapsto t_1]$.

```
if (a != 0 && b > a) {  
    b = b - a;  
}
```

```
t2 := t0  
t3 := 0  
COND t2 != t3 label2 label4  
LABEL label2  
t4 := t1  
t5 := t0  
COND t4 > t5 label3 label4  
LABEL label3  
t6 := t1  
t7 := t0  
t1 := t6 - t7  
LABEL label4
```

- ▶ Não existem operadores lógicos na linguagem intermédia (são implementados como saltos condicionais)
- ▶ Alternativa: tratar operadores lógico tal como os aritméticos (mas isso obrigaria a avaliar **ambos** os argumentos)
- ▶ *Cond* e *Exp* têm muita sobreposição (gramática âmbigua)
- ▶ Alternativa: uma só categoria gramatical *Exp* e duas funções de tradução mutuamente recursivas

$$\text{transExpr} : (\text{Exp}, \text{Table}, \text{Temp}) \rightarrow [\text{Instr}]$$
$$\text{transCond} : (\text{Exp}, \text{Table}, \text{Label}, \text{Label}) \rightarrow [\text{Instr}]$$

Usamos *transExpr* nas expressões e *transCond* nas condições de *if* e *while*

- ▶ Indexar arrays

$$Exp \rightarrow \dots \mid \mathbf{id}[Exp]$$

- ▶ Atribuir um índice de um array

$$Stm \rightarrow \dots \mid \mathbf{id}[Exp] := Exp$$

- ▶ Novas instruções de código intermédio para ler e escrever na memória

$$Instr \rightarrow \dots$$
$$\mid \mathbf{temp} := M[Atom]$$
$$\mid M[Atom] := \mathbf{temp}$$

(Atom é um temporário ou uma constante.)

- ▶ Tabela de símbolos associa o nome do *array* ao **endereço base**
- ▶ Função auxiliar para calcular o endereço de um índice (exemplo: elementos de 4 *bytes*)
- ▶ Resultado: o **código** e o **temporário com o endereço**

```
transIndex (exp, table) =  case exp of
    id[exp1]                base = lookup(id, table)
                            addr = newTemp()
                            code1 = transExpr(exp1, table, addr)
                            return (code1 ++[addr := addr * 4, addr := addr + base], addr)
```

$$\begin{array}{ll} \text{transExpr } (\text{exp}, \text{table}, \text{dest}) & = \text{case } \text{exp} \text{ of} \\ \text{id}[e_1] & \quad (code_1, \text{addr}) = \text{transIndex}(\text{id}[e_1], \text{table}) \\ & \quad \text{return } code_1 \text{ ++ [dest := M[addr]]} \end{array}$$

$$\begin{array}{ll} \text{transStm } (\text{stm}, \text{table}) & = \text{case } \text{stm} \text{ of} \\ \text{id}[e_1] := e_2 & \quad (code_1, \text{addr}) = \text{transIndex}(\text{id}[e_1], \text{table}) \\ & \quad t = \text{newTemp}() \\ & \quad code_2 = \text{transExpr}(e_2, \text{table}, t) \\ & \quad \text{return } code_1 \text{ ++ code}_2 \text{ ++ [M[addr] := t]} \end{array}$$

- ▶ Necessitamos ainda de tratar declarações de *arrays* e alocar memória para os elementos
- ▶ A alocação pode ser **estática** (global) ou **dinâmica** (na *pilha* ou na *heap*)
- ▶ Alocação na pilha: próxima aula
- ▶ Alocação estática: declaramos espaço no segmento de *data*

```
// linguagem C
int my_array[10];
```

```
# Assembly MIPS
.data
my_array:    .space 40 # 4 bytes * 10 elementos
```