

Compiladores (CC3001)

Aula 12: Geração de código máquina

Mário Florido

DCC/FCUP

2024

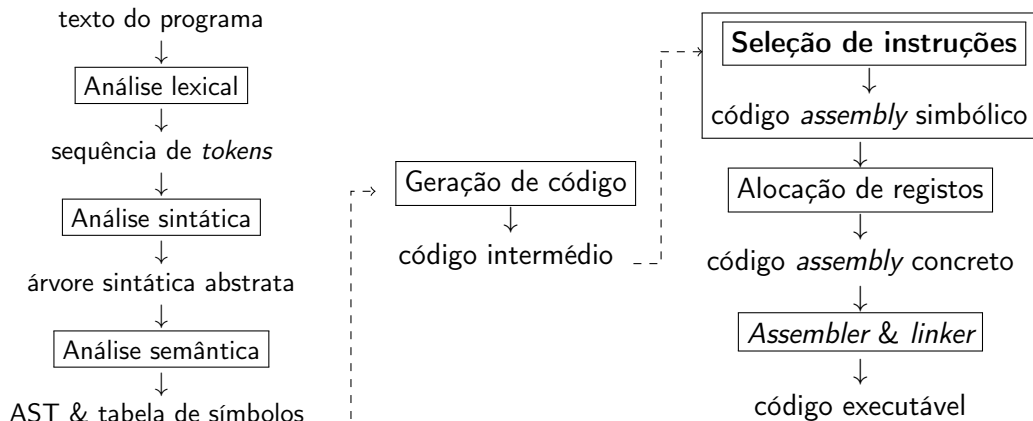


Código máquina simbólico

Código intermédio vs. código máquina

Padrões de instruções

Geração de código máquina



Código máquina simbólico

Código intermédio vs. código máquina

Padrões de instruções

Geração de código máquina

- ▶ Representação textual de código máquina
- ▶ Mais legível do que código binário
- ▶ Etiquetas simbólicas para endereços e constantes
- ▶ Transformada em código máquina executável por um programa *assemblador*

- ▶ Arquitetura RISC
- ▶ 32 registos inteiros \$0 – \$31 de 32-bits
- ▶ Conjunto de instruções *load/store*
- ▶ Instruções de tamanho fixo (32-bits)
- ▶ Operações entre 3 registos ou registos e constantes (*immediate*)
- ▶ Relembrar Arquitetura de Computadores:
<https://www.dcc.fc.up.pt/~ricroc/aulas/2324/ac/>

- \$0 sempre zero (\$zero)
- \$1 temporário do *assembler*
- \$2–\$3 valores de retorno (\$v0–\$v1)
- \$4–\$7 argumentos (\$a0–\$a3)
- \$26–\$27 reservados para *kernel*
- \$28 global pointer (\$gp)
- \$29 stack pointer (\$sp)
- \$30 frame pointer (\$fp)
- \$31 return address (\$ra)
- \$8–\$25 temporários \$t0–\$t7, \$s0–\$s7 e \$t8–\$t9

```
.data                                # dados
val:                                # array de constantes
    .word 10, -14, 30
str:                                # string terminada em zero
    .ascii "Hello!"
_heap_:                             # reservar 10k bytes
    .space 10000
.text                               # instruções
.global main                        # main é visível do exterior
la $gp, _heap_                     # inicializar reg $28 = _heap_
jal main                           # jump and link (reg $31)

_stop_:
li $2, 10                           # reg $2 = 10
syscall                             # syscall 10: exit

main:
la $8, val                          # reg $8 = val
lw $9, 4($8)                        # reg $9 = val[1]
addi $9, $9, 4                      # reg $9 = reg $9 + 4
sw $9, 8($8)                        # val[2] = reg $9
jr $ra                             # jump register $31 (return address)
```


Código máquina simbólico

Código intermédio vs. código máquina

Padrões de instruções

Geração de código máquina

1. O código máquina tem um número finito de registos
2. Não existe instrução CALL, i.e. tem de ser implementada com registos e pilha
3. As instruções de saltos condicionais têm só um destino
4. Pode ser necessário efetuar a comparação separadamente do salto condicional
5. Arquiteturas RISC só permitem instruções com constantes pequenas

O pontos 1 e 2 serão abordados separadamente (**alocação de registos** e **implementação de chamada de funções**).

Hoje vamos ver os pontos 3–5.

COND *c* *labelt* *labelf* pode ser traduzido como

```
branch_if_c    labelt  
jump           labelf
```

COND *c* *labelt* *labelf* pode ser traduzido como

```
branch_if_c    labelt  
jump           labelf
```

Se a próxima instrução for *labelt* ou *labelf* podemos eliminar um salto:

```
COND c labelt labelf  
LABEL labelt  
...
```

pode ser traduzido como

```
branch_if_not_c labelf  
labelt: ....
```

COND *c* *labelt* *labelf* pode ser traduzido como

```
branch_if_c    labelt  
jump          labelf
```

Se a próxima instrução for *labelt* ou *labelf* podemos eliminar um salto:

```
COND c labelt labelf  
LABEL labelt  
...
```

pode ser traduzido como

```
branch_if_not_c labelf  
labelt: ....
```

(Mantemos *labelt* porque pode ser referido noutra instrução.)

Em muitas arquiteturas as comparações devem ser efetuadas separadamente do salto: primeiro efetuamos a comparação e depois efetuamos salto.

Exemplos:

- ▶ Em MIPS comparações $=$ e \neq são diretas (beq e bne) mas $<$, $>$ etc. devem calcular a condição num registo (slt, sgt, etc.)
- ▶ Em ARM e X86 as operações aritméticas marcam *flags* (zero, negativo, *overflow*, *carry*, ...)

Comparação = em MIPS:

```
beq $t1, $t2, ltrue    # se $t1==$t2 ir para ltrue  
...                   # caso contrário
```

Comparação < em MIPS:

```
slt $1, $t1, $t2       # comparar $t1 < $t2 e guardar em $1  
bne $1, $zero, ltrue   # se $1 diferente de zero ir para ltrue  
...                   # caso contrário
```

(Usamos o registo \$1 como temporário.)

Frequentemente as instruções de código máquina permitem apenas constantes de tamanho limitado:

- ▶ MIPS suporta apenas constantes de 16 bits; para constantes maiores usamos `lui` para carregar 16 bits na metade superior de um registo
- ▶ ARM suporta apenas constantes de 8 bits que podem ser colocadas em diferentes posições de um registo

A geração de código deve decompor em várias instruções se necessário.

Por exemplo, a atribuição

```
t0 := 0x87fe000
```

corresponde a 2 instruções MIPS (usando `$1` como temporário):

```
lui $1,0x87          # $1 = 0x870000  
ori $t0, $1, 0xfe00  # $t0 = 0x87fe00
```


- ▶ MIPS suporta *pseudo-instruções* que facilitam a geração de código, e.g.
 - ▶ `blt`, `bgt`, `ble`, `bge` (*branch*) com condições $<$, $>$, \leq , \geq
 - ▶ `li` (*load immediate*) com constantes > 16 bits
 - ▶ move entre registos
- ▶ Não são implementadas em *hardware*
- ▶ Traduzidas para sequências de instruções básicas pelo assembler; e.g.:

pseudo-instrução	tradução
<code>move \$t1, \$t2</code>	<code>addu \$t1, \$zero, \$t2</code>
<code>li \$t0, 0x87fe00</code>	<code>lui \$1, 0x87</code> <code>ori \$t0, \$1, 0xfe00</code>
<code>blt \$t0, \$t1, label</code>	<code>slt \$1, \$t0, \$t1</code> <code>bne \$1, \$zero, label</code>

Código máquina simbólico

Código intermédio vs. código máquina

Padrões de instruções

Geração de código máquina

- ▶ Vamos traduzir **padrões de instruções intermédias** em instruções de código máquina
- ▶ Preferimos padrões mais longos se possível (mais vantajoso)
- ▶ Se não for possível: padrões para instruções individuais

COND $r_s = r_t$ $label_t$ $label_f$, LABEL $label_f$	beq $r_s, r_t, label_t$ $label_f:$
COND $r_s = r_t$ $label_t$ $label_f$, LABEL $label_t$	bne $r_s, r_t, label_f$ $label_t:$
COND $r_s = r_t$ $label_t$ $label_f$	beq $r_s, r_t, label_t$ j $label_f$
COND $r_s < r_t$ $label_t$ $label_f$, LABEL $label_f$	blt* $r_s, r_t, label_t$ $label_f:$
COND $r_s < r_t$ $label_t$ $label_f$, LABEL $label_t$	bge* $r_s, r_t, label_f$ $label_t:$
COND $r_s < r_t$ $label_t$ $label_f$	blt* $r_s, r_t, label_t$ j $label_f$
LABEL $label$	$label:$
JUMP $label$	j $label$

(* são *pseudo*-instruções.)

$r_d := r_s + r_t$	add r_d, r_s, r_t
$r_d := r_s + k$	addi r_d, r_s, k
$r_d := r_s * r_t$	mul r_d, r_s, r_t
$r_d := r_t$	move r_d, r_t
$r_d := k$	li r_d, k
$r_t := M[r_s]$	lw $r_t, 0(r_s)$
$M[r_s] := r_t$	sw $r_t, 0(r_s)$

É necessário tratar todas as possibilidades do código intermédio (e.g. as restantes operações aritméticas).

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:
```

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:  
    bge $t1, $t2, label2  
label1:  
    
```


Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:  
    bge $t1, $t2, label2  
label1:  
    move $t3, $t2
```

Código intermédio

```
LABEL max
COND t1<t2 label1 label2
LABEL label1
t3 := t2
JUMP label3
LABEL label2
t3 := t1
LABEL label3
```

Código MIPS

```
max:
    bge $t1, $t2, label2
label1:
    move $t3, $t2
    j label3
```

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:  
    bge $t1, $t2, label2  
label1:  
    move $t3, $t2  
    j label3  
label2:
```

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:  
    bge $t1, $t2, label2  
label1:  
    move $t3, $t2  
    j label3  
label2:  
    move $t3, $t1
```

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:  
    bge $t1, $t2, label2  
label1:  
    move $t3, $t2  
    j label3  
label2:  
    move $t3, $t1  
label3:
```

Código intermédio

```
LABEL max  
COND t1<t2 label1 label2  
LABEL label1  
t3 := t2  
JUMP label3  
LABEL label2  
t3 := t1  
LABEL label3
```

Código MIPS

```
max:  
    bge $t1, $t2, label2  
label1:  
    move $t3, $t2  
    j label3  
label2:  
    move $t3, $t1  
label3:
```

- ▶ Seguimos um **algoritmo guloso**:
 1. traduzir o maior padrão que encaixa o prefixo de código;
 2. repetir para o restante
- ▶ Alternativa: atribuir custos a cada instrução de máquina; encontrar o encaixe que minimiza o custo total usando **programação dinâmica**
- ▶ A primeira abordagem é mais simples e funciona bem em arquiteturas RISC

- ▶ O cálculo de endereços necessita de multiplicar índices pelo tamanho dos elementos (e.g. 4 bytes para inteiros 32-bits)
- ▶ Se o tamanho for potência de 2: em vez de multiplicação podemos usar uma operação de *left shift* (mais eficiente)

- ▶ Exemplo: podemos traduzir $t1 := t1 * 8$ por

`sll $t1, $t1, 3`

(porque $8 = 2^3$)

- ▶ Caso geral: traduzimos

$$r_d := r_s * 2^k$$

por

`sll r_d , r_s , k`

Consider a seguinte atribuição em C:

```
int x[N], i;  
...  
x[i] = 5;
```

(Assumindo $[x \mapsto t_0, i \mapsto t_1]$.)

Código intermédio:

```
t2 := t1  
t2 := t2*4  
t2 := t2 + t0  
t4 := 5  
M[t2] := t4
```

Código MIPS:

```
move $t2, $t1  
sll $t2, $t2, 2  
add $t2, $t2, t0  
li $t4, 5  
sw $t4, 0($t2)
```

Muitas arquiteturas permitem combinar várias operações numa só instrução de máquina:

- ▶ operações *load/store* que efetuam cálculos de endereços;
- ▶ operações aritméticas combinando *add* e *shifts*;
- ▶ instruções que transferem múltiplos registos de/para memória

Podemos traduzir **várias instruções intermédias** → **uma instrução de máquina**.

As duas instruções intermédias:

$$t2 := t1 + 8$$
$$t3 := M[t2]$$

podem ser combinadas numa só instrução MIPS:

$$\text{lw } \$t3, 8(\$t1)$$

As duas instruções intermédias:

$$t2 := t1 + 8$$
$$t3 := M[t2]$$

podem ser combinadas numa só instrução MIPS:

$$\text{lw } \$t3, 8(\$t1)$$

Mas: **apenas se o valor de $t2$ não for mais usado!**

Podemos descobrir essa informação por meio de **análise semântica de *liveness* das variáveis** (mais tarde).

Código máquina simbólico

Código intermédio vs. código máquina

Padrões de instruções

Geração de código máquina

- ▶ Nos padrões de código intermédios apresentados assumimos que as variáveis temporárias correspondem aos registos
- ▶ Para atribuir registos a temporários de forma ótima é necessária uma análise separada (**alocação de registos**)
- ▶ Alternativa mais simples:
 - ▶ re-utilizar temporários durante geração de código intermédio
 - ▶ atribuir cada temporário a um registo MIPS diferente
 - ▶ pode não compilar programas com expressões muito longas. . .
 - ▶ . . . mas é suficiente para o projeto laboratorial (porque a arquitetura MIPS tem bastantes registos)

- ▶ O esquema de tradução para código intermédio introduz sempre variáveis intermédias para sub-expressões
- ▶ Mas sabemos que essas variáveis não serão mais necessárias
- ▶ Logo: podemos **re-utilizar em expressões seguintes**

transExp (expr, table, dest) = case expr of

\vdots
 $e_1 \text{ binop } e_2$

$t_1 = \text{newTemp}()$
 $t_2 = \text{newTemp}()$
 $\text{code}_1 = \text{transExp}(e_1, \text{table}, t_1)$
 $\text{code}_2 = \text{transExp}(e_2, \text{table}, t_2)$
 $\text{popTemp}(2)$ (t_1, t_2 não vão ser mais necessários)
 $\text{return } \text{code}_1 ++ \text{code}_2 ++ [\text{dest} := t_1 \text{ binop } t_2]$

A operação popTemp apenas decrementa o contador de temporários:

```
int temp_count = 0;  // contador global
```

```
int newTemp() {  
    return temp_count ++;  
}
```

```
void popTemp(int k) {  
    temp_count -= k;  
}
```

O número de temporários usados numa função será a **profundidade máxima** das expressões aritméticas (independente do número de instruções).


```
int f (int x, int y) {  
    return 3*x + 2*y;  
}
```

```
f(a0, a1) [  
    t3 := 3  
    t4 := a0  
    t1 := t3 * t4  
    t3 := 2  
    t4 := a1  
    t2 := t3 * t4  
    t0 := t1 + t2  
    RETURN t0  
]
```

- ▶ Na tradução para código máquina podemos usar registos \$t0-\$t4 para temporários
- ▶ Na próxima aula: veremos como tratar argumentos e valores de retorno